





Analyse Discriminante Quadratique

Fondements historiques, intuition géométrique et modélisation mathématique des frontières de décision.

Réalisé par : Attioui Ferdaous




L'origine linéaire.

Introduite par **Ronald Fisher** en 1936 pour classifier des espèces d'Iris.

La contrainte fondamentale : l'**homoscédasticité**.
Toutes les classes sont forcées de partager la même matrice de **variance-covariance**.

La frontière est strictement droite.




L'adaptation quadratique (QDA).

Face aux données réelles complexes, la contrainte linéaire s'effondre.


La QDA tolère l'**hétéroscédasticité** :
chaque classe possède sa propre structure de **variabilité géométrique**.

Le résultat : des frontières de décision courbes et organiques.

Le Choc des Hypothèses Géométriques



Matrice de covariance partagée. Tous les groupes se dispersent de manière identique.
Frontière forcée : Ligne droite ou *hyperplan*.



Matrices de covariance spécifiques.
La QDA s'adapte à la forme, l'orientation et l'étalement uniques de chaque groupe.
Frontière adaptative : Courbes complexes.

L'Empreinte Digitale Mathématique d'une Classe

Théorème de Bayes :
Profil de la classe k



$$\pi_k = \frac{N_k}{N}$$

La proportion initiale des données appartenant à la classe k avant toute analyse.



$$\mu_k$$

Le centre de gravité géométrique du groupe.



$$\Sigma_k$$

La matrice spécifique capturant l'orientation et la dispersion géométrique propre à la classe.

L'Anatomie de la Fonction de Score

$$\delta_k(\mathbf{X}) = \underbrace{-\frac{1}{2} \ln |\Sigma_k|}_{\text{Pénalité de Dispersion}} - \underbrace{\frac{1}{2} (\mathbf{X} - \mu_k)^T \Sigma_k^{-1} (\mathbf{X} - \mu_k)}_{\text{Distance de Mahalanobis}} + \underbrace{\ln(\pi_k)}_{\text{Poids Initial}}$$

Pénalité de Dispersion

Sanctionne les classes ayant un volume trop vaste pour éviter qu'elles n'absorbent tout l'espace.



Distance de Mahalanobis

Mesure l'éloignement du point $\mathbf{X}$ au centre μ_k , en épousant les corrélations dictées par la matrice Σ_k .




Poids Initial

Le biais mathématique en faveur des classes majoritaires.



L'Origine de la Courbe




- La présence de la variable d'observation X multipliée par elle-même à travers l'inverse de la matrice (Σ_k^{-1}) fait émerger un terme quadratique (X^2) .
- Géométriquement, l'intersection de ces espaces quadratiques projette des frontières non-linéaires sur notre espace de données, créant les paraboles, hyperboles et ellipses caractéristiques de la QDA.

Matrice de Décision Stratégique

	LDA	QDA
Flexibilité des frontières	Lignes droites rigides. 	Courbes adaptatives et complexes. 
Hypothèse de variance	Homoscédasticité (Test de Box validé). 	Hétéroscédasticité évidente. 
Complexité paramétrique	Faible (Une seule matrice globale). Σ	Élevée ($\frac{p(p+1)}{2}$ paramètres par classe). Σ_k
Risque de surapprentissage	Faible. 	Très élevé (overfitting). 
Volume de données idéal	Restreint ou avec beaucoup de variables. 	Échantillon d'apprentissage massif. 

Le Paradoxe de la Flexibilité



La flexibilité mathématique est une arme à double tranchant. La QDA offre des frontières parfaites, mais exige le calcul d'une matrice de covariance complète pour chaque classe.

Si les données sont massives, la QDA révèle les véritables contours de la réalité. Si les données sont rares ou bruitées, la simplicité rigide de la LDA triomphera toujours du surapprentissage de la QDA.